



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ЛАБОРАТОРНАЯ РАБОТА № 2

по дисциплине «Машинное обучение»
на тему «Обучение без учителя. Понижение размерности. Обнаружение
аномалий. Кластеризация»

Выполнил:

Студент Войстрик А.А.

Группа ИПБП41

Проверил:

Дольников Максим Генадьевич

Ростов-на-Дону

2026 г.


Цель работы


Проанализировать многомерные входные данные для Варианта 12, выполнить отбор признаков методами понижения размерности (PCA, SVD, ICA), выявить шумовые компоненты, выполнить кластеризацию с помощью 12 алгоритмов библиотеки `scikit-learn` и обнаружить аномальные значения (выбросы). Добавить работу в собственный репозиторий GitHub: https://github.com/Absult56/ML_lab2

1. Понижение размерности и отбор признаков

1.1–1.2 Матрицы взаимных корреляций и разброса признаков

- На основе тепловой карты взаимных корреляций установлено, что линейная связь между пятью признаками практически отсутствует. Все коэффициенты корреляции по модулю малы и не превышают 0.10.
- Матрица разброса признаков (scatter matrix) подтверждает слабую коррелированность: проекции парных распределений представляют собой изотропные облака точек без выраженных функциональных зависимостей или наклонов.






1.3–1.4 Оценка значимости компонент и зашумленности (PCA, SVD, ICA)

- Из-за отсутствия явных взаимных зависимостей между исходными признаками гистограммы объясненной дисперсии для методов PCA и SVD имеют пологий характер убывания:
 - **Главные компоненты:** 1-я и 2-я компоненты, суммарно объясняющие порядка 45% совокупной дисперсии (24% и 21% соответственно).
 - **Второстепенные компоненты:** 3-я и 4-я компоненты (около 19% и 18% дисперсии).

- **Шумовые/малозначимые компоненты:** 5-я компонента дает минимальный вклад (около 17%). При этом выраженных шумовых компонент с нулевой дисперсией в данных Варианта 12 нет, все признаки несут полезную информацию.



- В анализе независимых компонент (ICA) на основе нормализованного куртозиса наиболее информативной (наименее гауссовской) оказалась 2-я компонента, за ней следуют 3-я и 4-я.




1.5 Biplot-графики проекций данных

- На двумерных проекциях векторов признаков (loadings) для PCA, SVD и ICA стрелки направлены в разные стороны под широкими углами, что отражает ортогональность исходных признаков и подтверждает отсутствие мультиколлинеарности.

- Поскольку первые две компоненты удерживают менее половины всей информации, проекции истинных классов данных в двумерном пространстве частично накладываются друг на друга.






2. Кластеризация и обнаружение аномалий

2.1–2.2 Анализ алгоритмов кластеризации


- **Алгоритмы на основе формы и расстояний (K-Means, Ward, Spectral, Birch, Bisecting K-Means):** Равномерно делят сплошное облако точек на выпуклые сегменты в соответствии с заданным числом кластеров.
- **Алгоритмы на основе плотности (DBSCAN, HDBSCAN, OPTICS):** Демонстрируют естественную форму данных — непрерывное центральное ядро с постепенным спадом плотности к периферии.
- **Неэффективные без тонкой настройки алгоритмы:** Mean-Shift при стандартном окне объединил весь массив в единый кластер, а Affinity Propagation создал чрезмерное количество фрагментов.



Подбор параметров и выделение аномалий

- На графике метода локтя точка перегиба находится в районе $k = 3$ и $k = 4$, что обосновывает выбор этого числа кластеров для центроидных алгоритмов.
- Для метода DBSCAN подобраны параметры $\text{eps} = 0.35$ и $\text{min_samples} = 6$, исключающие внутреннее разрушение плотного ядра.

- **Эффективность отделения выбросов:** плотностные алгоритмы изолировали шум, не искажая границы основного массива. Разреженные точки по внешним границам корректно помечены как аномалии (красные крестики), тогда как ядро сформировало целостный кластер.



2.5 Сравнение с эталонными метками и обоснование выбора лучшего алгоритма

- **Анализ эталонного распределения (Ground Truth):** В исходном датасете столбец корректных меток y содержит **3 класса** (по 100 объектов в классах 0 и 1, и 99 объектов в классе 2). При визуализации эталона видно, что кластеры не являются изолированными круглыми сферами: они имеют вытянутую эллиптическую форму с разными

направлениями дисперсии и существенно накладываются друг на друга в центральной области.

- **Количественное сравнение алгоритмов с эталоном:**

Для объективной оценки качества работы моделей относительно истинной разметки у были рассчитаны внешние метрики кластеризации: скорректированный индекс Рэнда (**ARI**) и нормализованная взаимная информация (**NMI**):


Алгоритм	Число кластеров	Выбросы (outliers)	ARI	NMI	Примечание
Gaussian Mixture (GMM)	3	0	0.6384	0.6027	Наилучшее совпадение с эталоном
Bisecting K-Means	3	0	0.2905	0.3433	Средний результат, дробит вытянутый кластер
K-Means	3	0	0.2581	0.3034	Ошибается на границах из-за сферических допущений
Spectral Clustering	3	0	0.2307	0.2636	Средний результат
DBSCAN	1	38	0.0245	0.0793	Объединил всё ядро в 1 кластер, отделив шум

- **Обоснование выбора лучшего алгоритма:**

1. **Провал плотностных методов при разбиении на классы:**
Алгоритмы DBSCAN и HDBSCAN превосходно справились с задачей 2.4 (поиск краевых аномалий), однако для задачи классификации по классам у они непригодны ($ARI = 0.02$). Поскольку истинные классы плавно переходят друг в друга без

нулевых зон плотности («пустот»), DBSCAN объединяет их в одно неделимое ядро.

2. **Ограниченность центроидных алгоритмов:** K-Means и Bisecting K-Means ищут сферические сгустки равного размера. Из-за этого нижний вытянутый кластер был искусственно разрезан пополам, что дало низкий показатель ARI (около 0.26–0.29).
3. **Победа Gaussian Mixture Model (GMM):** Модель гауссовых смесей показала абсолютное превосходство (**ARI = 0.6384, NMI = 0.6027**). Благодаря использованию индивидуальных ковариационных матриц для каждой гауссианы, GMM смогла учесть вытянутую геометрию и разную ориентацию кластеров, практически точно восстановив исходную скрытую разметку выборки.



Вывод

В ходе выполнения лабораторной работы были изучены и применены на практике методы обучения без учителя: алгоритмы понижения размерности (PCA, SVD, ICA), методы кластеризации и алгоритмы обнаружения аномалий.

На основе анализа данных **Варианта 12** сформированы следующие результаты:

- **Понижение размерности и отбор признаков:** Матрицы взаимных корреляций и разброса признаков показали отсутствие сильной

линейной взаимосвязи между признаками (коэффициенты корреляции не превышают 0.10). Из-за независимости признаков методы PCA и SVD продемонстрировали равномерное распределение объясненной дисперсии между компонентами (от 24% для 1-й до 17% для 5-й) без резких скачков. В данных отсутствуют явные шумовые компоненты с околонулевой дисперсией, однако 5-я компонента вносит минимальный вклад и может быть исключена при компрессии. Метод ICA выделил 2-ю компоненту как наиболее негауссовскую (информативную). Графики Biplot подтвердили ортогональность направлений признаков и частичное перекрытие классов в проекции первых двух компонент.

- **Определение структуры данных и числа кластеров:** График «метода локтя» зафиксировал выраженную точку излома на значениях $k = 3$ и $k = 4$, что позволило обоснованно задать гиперпараметры для центроидных алгоритмов кластеризации.

- **Сравнение алгоритмов кластеризации:** Алгоритмы пространственного разделения (K-Means, Ward, Spectral, Birch) искусственно сегментируют единый массив на выпуклые области. В то же время алгоритмы на основе плотности (DBSCAN, HDBSCAN) выявили естественную структуру распределения — непрерывное центральное ядро с постепенным спадом плотности к периферии. Алгоритмы Mean-Shift и Affinity Propagation при базовых параметрах оказались неэффективными, объединив все точки в единую группу либо чрезмерно фрагментировав выборку.

- **Обнаружение аномалий и выбор лучшего метода:** Настройка параметров DBSCAN (**eps = 0.35**, **min_samples = 6**) позволила эффективно отделить разреженный шум на внешних границах датасета от целостного ядра. С точки зрения сохранения истинной топологии данных и очистки от выбросов наиболее эффективными показали себя алгоритмы **DBSCAN** и **HDBSCAN**. При необходимости жесткого разбиения пространства предпочтительным является метод **Gaussian Mixture (GMM)** с $k = 3$,

обеспечивающий более гибкую вероятностную аппроксимацию эллиптических границ кластеров по сравнению с K-Means.