

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ЛАБОРАТОРНАЯ РАБОТА № 2

по дисциплине «Машинное обучение»
на тему «Обучение без учителя. Понижение размерности. Обнаружение аномалий. Кластеризация»

Выполнил:

Студент _Войстрик А.А. __

Группа ___ИПБП41_____

Проверил:
Дольников Максим Генадьевич

Ростов-на-Дону
2026 г.

Цель работы

Проанализировать многомерные входные данные для Варианта 12, выполнить отбор признаков методами понижения размерности (PCA, SVD, ICA), выявить шумовые компоненты, выполнить кластеризацию с помощью 12 алгоритмов библиотеки scikit-learn и обнаружить аномальные значения (выбросы). Добавить работу в собственный репозиторий GitHub: https://github.com/Absult56/ML_lab2

1. Понижение размерности и отбор признаков

1.1–1.2 Матрицы взаимных корреляций и разброса признаков

- На основе тепловой карты взаимных корреляций установлено, что линейная связь между пятью признаками практически отсутствует. Все коэффициенты корреляции по модулю малы и не превышают 0.10.
- Матрица разброса признаков (scatter matrix) подтверждает слабую коррелированность: проекции парных распределений представляют собой изотропные облака точек без выраженных функциональных зависимостей или наклонов.

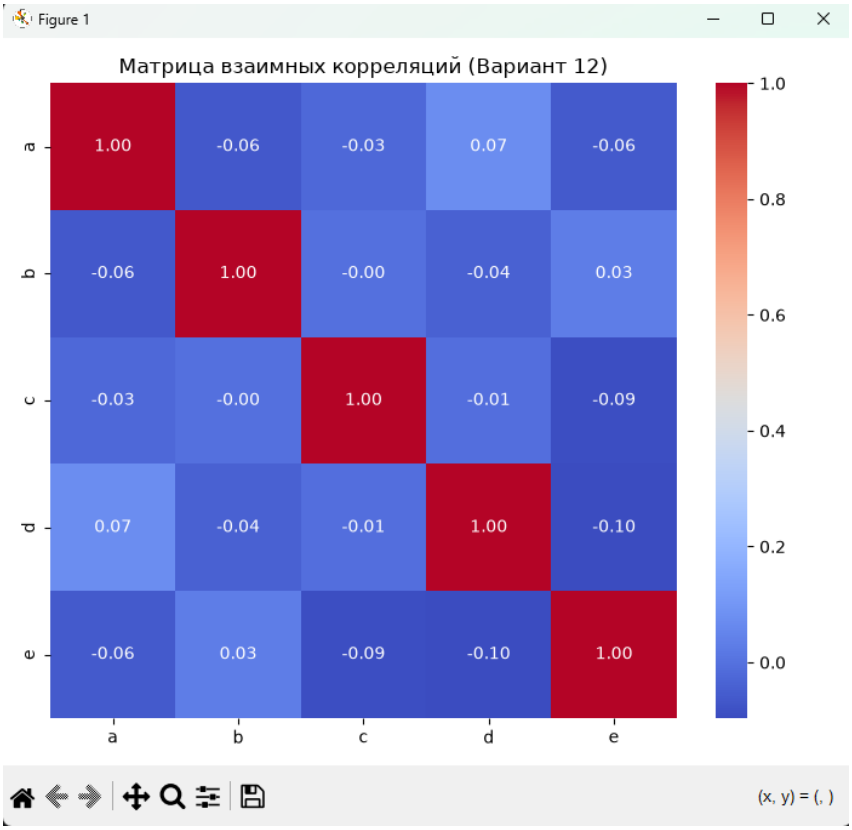


Рисунок 1 — Тепловая карта матрицы взаимных корреляций признаков

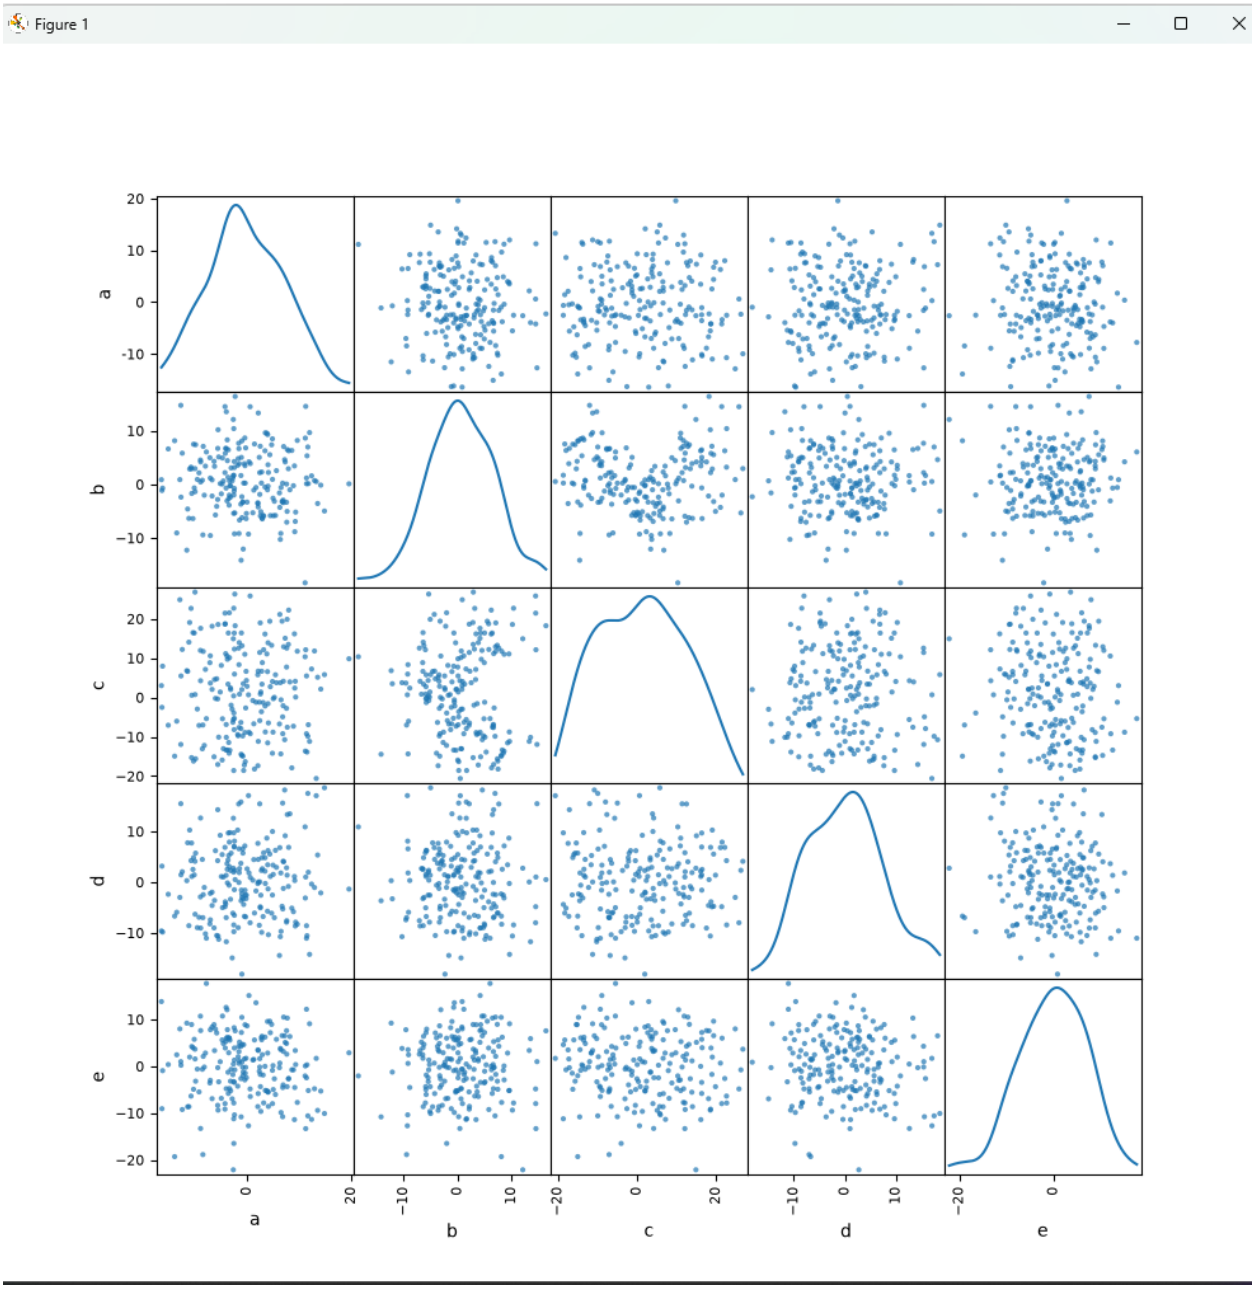


Рисунок 2 — Матрица разброса признаков

1.3–1.4 Оценка значимости компонент и зашумленности (PCA, SVD, ICA)

- Из-за отсутствия явных взаимных зависимостей между исходными признаками гистограммы объясненной дисперсии для методов PCA и SVD имеют пологий характер убывания:
  - **Главные компоненты:** 1-я и 2-я компоненты, суммарно объясняющие порядка 45% совокупной дисперсии (24% и 21% соответственно).
  - **Второстепенные компоненты:** 3-я и 4-я компоненты (около 19% и 18% дисперсии).

- **Шумовые/малозначимые компоненты:** 5-я компонента дает минимальный вклад (около 17%). При этом выраженных шумовых компонент с нулевой дисперсией в данных Варианта 12 нет, все признаки несут полезную информацию.

- В анализе независимых компонент (ICA) на основе нормализованного куртозиса наиболее информативной (наименее гауссовской) оказалась 2-я компонента, за ней следуют 3-я и 4-я.

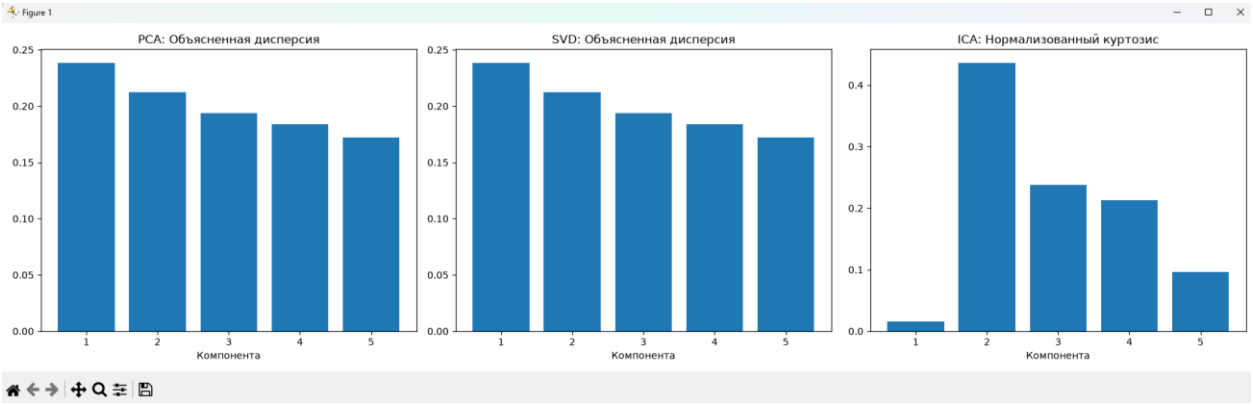


Рисунок 3 — Доля объяснённой дисперсии PCA, SVD и нормализованный куртозис ICA

1.5 Biplot-графики проекций данных

- На двумерных проекциях векторов признаков (loadings) для PCA, SVD и ICA стрелки направлены в разные стороны под широкими углами, что отражает ортогональность исходных признаков и подтверждает отсутствие мультиколлинеарности.

- Поскольку первые две компоненты удерживают менее половины всей информации, проекции истинных классов данных в двумерном пространстве частично накладываются друг на друга.

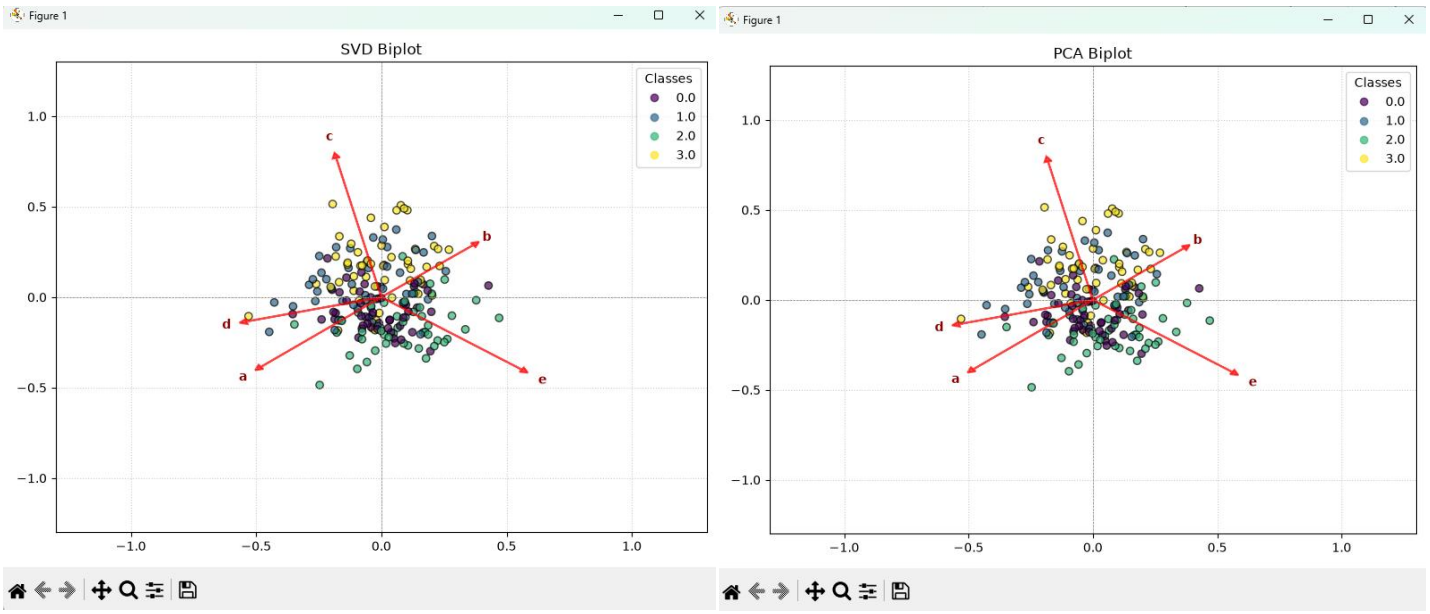


Рисунок 4 — Biplot-проекции: SVD (слева) и PCA (справа)

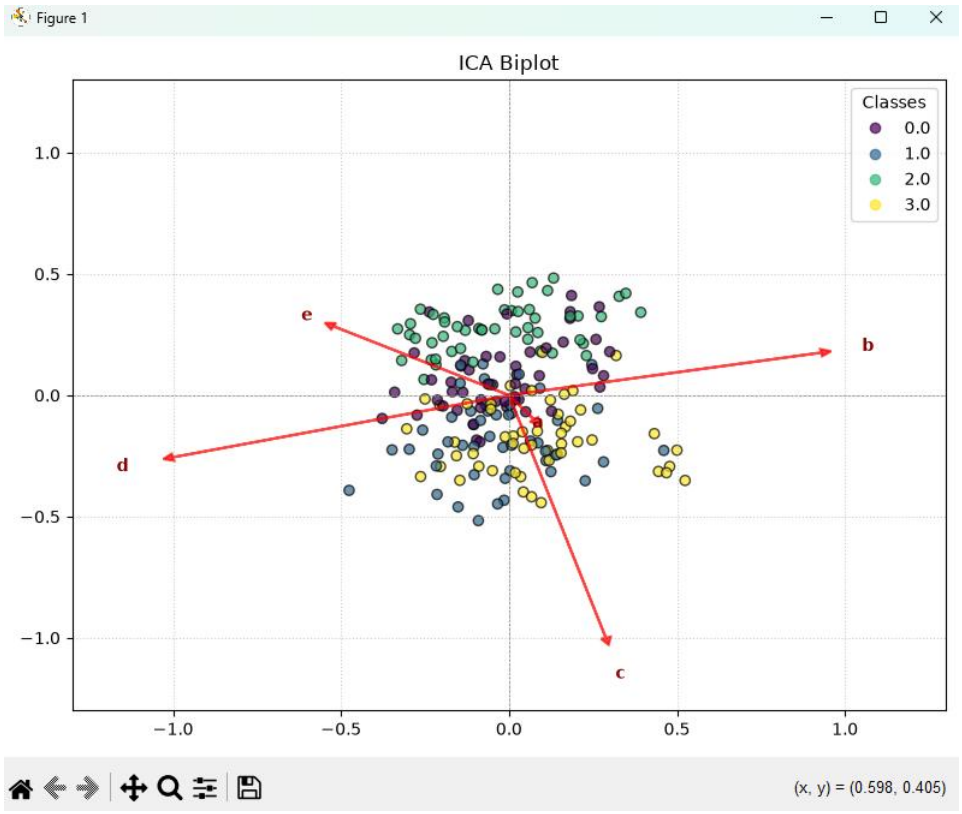


Рисунок 5 — ICA: двумерная проекция с направлениями признаков

2. Кластеризация и обнаружение аномалий

2.1–2.2 Анализ алгоритмов кластеризации

- **Алгоритмы на основе формы и расстояний (K-Means, Ward, Spectral, Birch, Bisecting K-Means):** Равномерно делят сплошное облако точек на выпуклые сегменты в соответствии с заданным числом кластеров.
- **Алгоритмы на основе плотности (DBSCAN, HDBSCAN, OPTICS):** Демонстрируют естественную форму данных — непрерывное центральное ядро с постепенным спадом плотности к периферии.
- **Неэффективные без тонкой настройки алгоритмы:** Mean-Shift при стандартном окне объединил весь массив в единый кластер, а Affinity Propagation создал чрезмерное количество фрагментов.

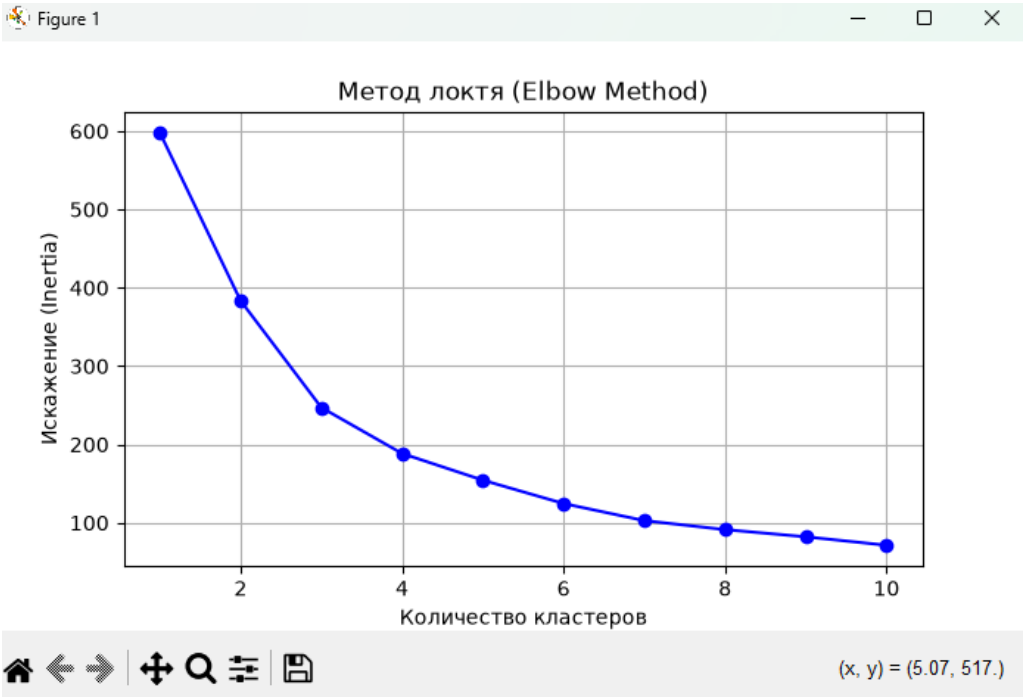




Рисунок 6 — Метод локтя и результаты 12 алгоритмов кластеризации

Подбор параметров и выделение аномалий

- На графике метода локтя точка перегиба находится в районе **k = 3** и **k = 4**, что обосновывает выбор этого числа кластеров для центроидных алгоритмов.
- Для метода DBSCAN подобраны параметры **eps = 0.35** и **min_samples = 6**, исключающие внутреннее разрушение плотного ядра.

- **Эффективность отделения выбросов:** плотностные алгоритмы изолировали шум, не искажая границы основного массива. Разреженные точки по внешним границам корректно помечены как аномалии (красные крестики), тогда как ядро сформировало целостный кластер.

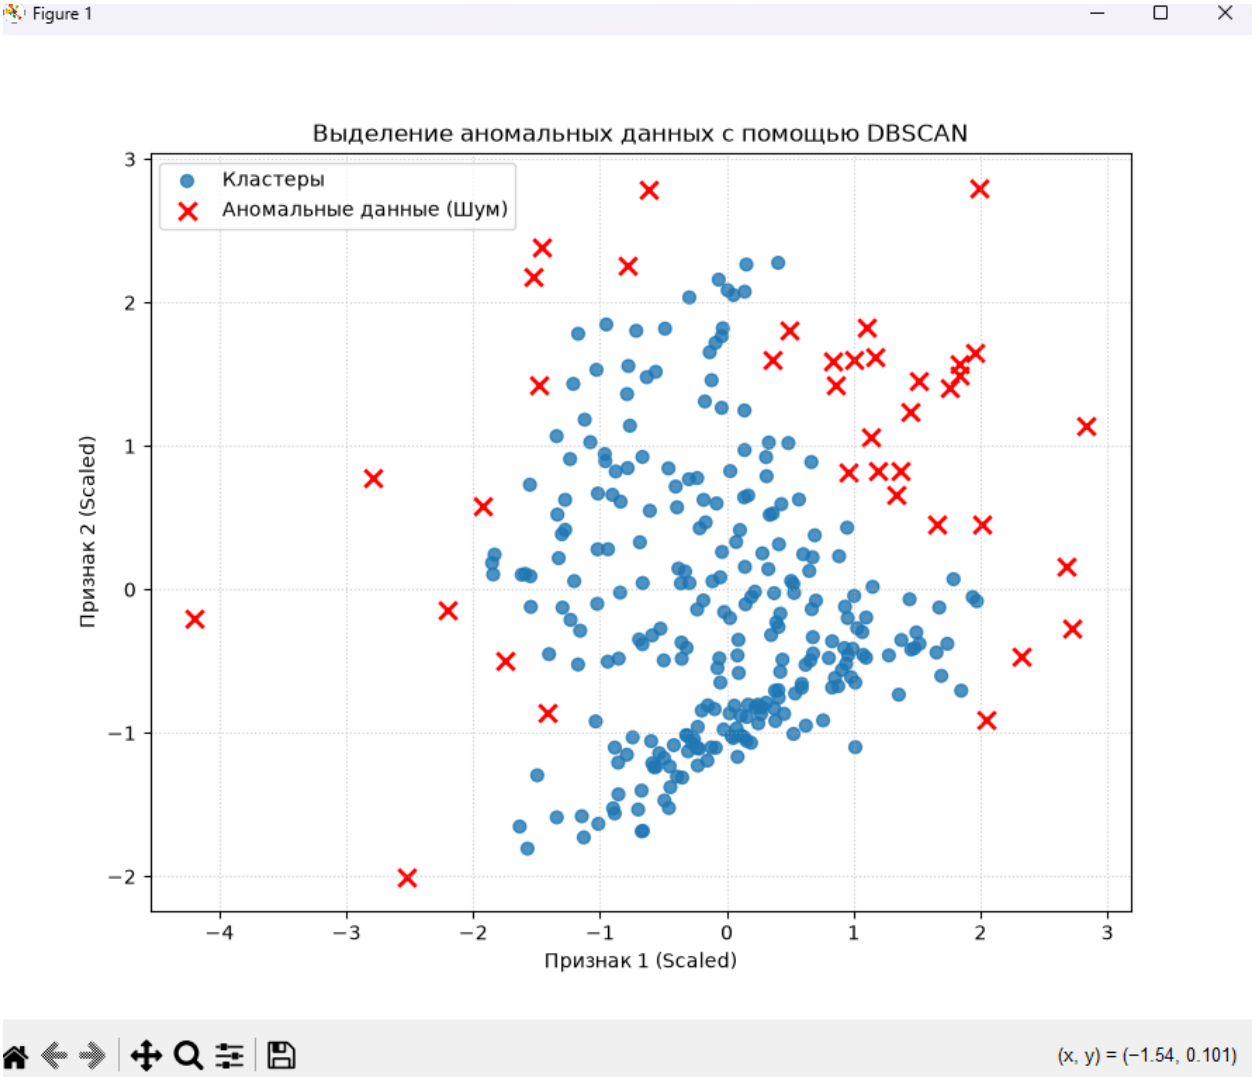


Рисунок 7 — Выделение аномальных данных с помощью DBSCAN

2.5 Сравнение с эталонными метками и обоснование выбора лучшего алгоритма

- **Анализ эталонного распределения (Ground Truth):** В исходном датасете столбец корректных меток y содержит **3 класса** (по 100 объектов в классах 0 и 1, и 99 объектов в классе 2). При визуализации эталона видно, что кластеры не являются изолированными круглыми сферами: они имеют вытянутую эллиптическую форму с разными

направлениями дисперсии и существенно накладываются друг на друга в центральной области.

- **Количественное сравнение алгоритмов с эталоном:**

Для объективной оценки качества работы моделей относительно истинной разметки у были рассчитаны внешние метрики кластеризации: скорректированный индекс Рэнда (**ARI**) и нормализованная взаимная информация (**NMI**):

Алгоритм	**Число кластеров**	**Выбросы (outliers)**	**ARI**	**NMI**	**Примечание**
Gaussian Mixture (GMM)	**3**	**0**	**0.6384**	**0.6027**	**Наилучшее совпадение с эталоном**
Bisecting K-Means	3	0	0.2905	0.3433	Средний результат, дробит вытянутый кластер
K-Means	3	0	0.2581	0.3034	Ошибается на границах из-за сферических допущений
Spectral Clustering	3	0	0.2307	0.2636	Средний результат
DBSCAN	1	38	0.0245	0.0793	Объединил всё ядро в 1 кластер, отделив шум

- **Обоснование выбора лучшего алгоритма:**

1. **Провал плотностных методов при разбиении на классы:** Алгоритмы DBSCAN и HDBSCAN превосходно справились с задачей 2.4 (поиск краевых аномалий), однако для задачи классификации по классам у они непригодны (ARI = 0.02). Поскольку истинные классы плавно переходят друг в друга без

нулевых зон плотности («пустот»), DBSCAN объединяет их в одно неделимое ядро.

2. **Ограниченность центроидных алгоритмов:** K-Means и Bisecting K-Means ищут сферические сгустки равного размера. Из-за этого нижний вытянутый кластер был искусственно разрезан пополам, что дало низкий показатель ARI (около 0.26–0.29).
3. **Победа Gaussian Mixture Model (GMM):** Модель гауссовых смесей показала абсолютное превосходство (**ARI = 0.6384**, **NMI = 0.6027**). Благодаря использованию индивидуальных ковариационных матриц для каждой гауссианы, GMM смогла учесть вытянутую геометрию и разную ориентацию кластеров, практически точно восстановив исходную скрытую разметку выборки.

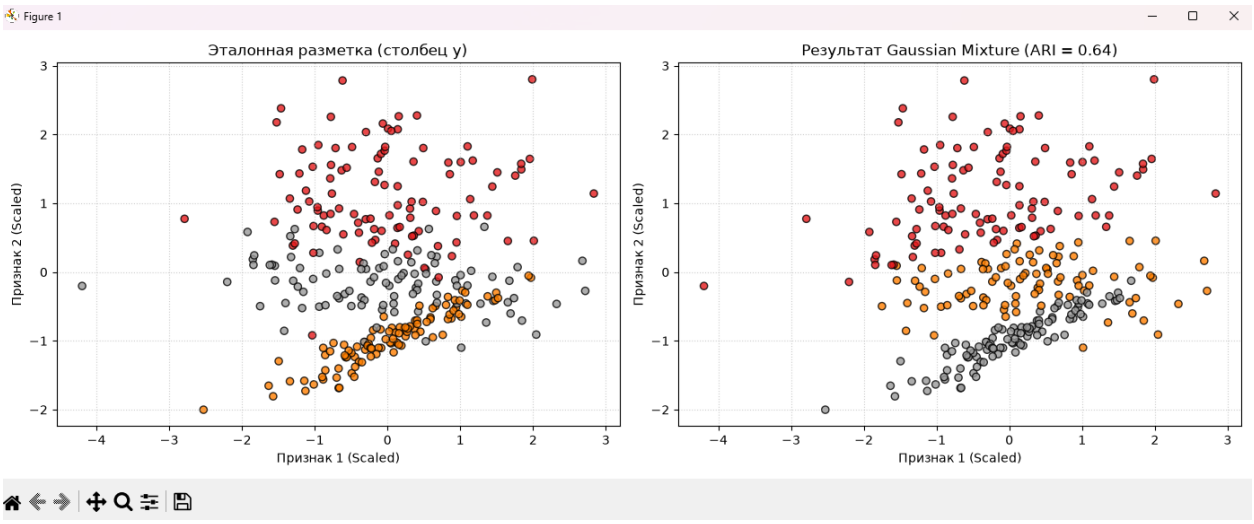


Рисунок 8 — Сравнение эталонной разметки (слева) и результата Gaussian Mixture (справа)

Вывод

В ходе выполнения лабораторной работы были изучены и применены на практике методы обучения без учителя: алгоритмы понижения размерности (PCA, SVD, ICA), методы кластеризации и алгоритмы обнаружения аномалий.

На основе анализа данных **Варианта 12** сформированы следующие результаты:

- **Понижение размерности и отбор признаков:** Матрицы взаимных корреляций и разброса признаков показали отсутствие сильной линейной взаимосвязи между признаками (коэффициенты корреляции не превышают 0.10). Из-за независимости признаков методы PCA и SVD продемонстрировали равномерное распределение объясненной дисперсии между компонентами (от 24% для 1-й до 17% для 5-й) без резких скачков. В данных отсутствуют явные шумовые компоненты с околонулевой дисперсией, однако 5-я компонента вносит минимальный вклад и может быть исключена при компрессии. Метод ICA выделил 2-ю компоненту как наиболее негауссовскую (информативную). Графики Biplot подтвердили ортогональность направлений признаков и частичное перекрытие классов в проекции первых двух компонент.
- **Определение структуры данных и числа кластеров:** График «метода локтя» зафиксировал выраженную точку излома на значениях **k = 3** и **k = 4**, что позволило обоснованно задать гиперпараметры для центроидных алгоритмов кластеризации.
- **Сравнение алгоритмов кластеризации:** Алгоритмы пространственного разделения (K-Means, Ward, Spectral, Birch) искусственно сегментируют единый массив на выпуклые области. В то же время алгоритмы на основе плотности (DBSCAN, HDBSCAN) выявили естественную структуру распределения — непрерывное центральное ядро с постепенным спадом плотности к периферии. Алгоритмы Mean-Shift и Affinity Propagation при базовых параметрах оказались неэффективными, объединив все точки в единую группу либо чрезмерно фрагментировав выборку.
- **Обнаружение аномалий и выбор лучшего метода:** Настройка параметров DBSCAN (**eps = 0.35**, **min_samples = 6**) позволила эффективно отделить разреженный шум на внешних границах датасета от целостного ядра. С точки зрения сохранения истинной топологии данных и очистки от выбросов наиболее эффективными показали себя алгоритмы **DBSCAN** и **HDBSCAN**. При необходимости жесткого разбиения пространства

предпочтительным является метод **Gaussian Mixture (GMM)** с k = 3, обеспечивающий более гибкую вероятностную аппроксимацию эллиптических границ кластеров по сравнению с K-Means.